

Predicción del precio semanal de frutas en Chile mediante Machine Learning

1. Descripción general

Este proyecto desarrolla un modelo de Machine Learning para estimar el precio promedio semanal de distintas frutas comercializadas en Chile.

El trabajo utiliza información pública publicada por la Oficina de Estudios y Políticas Agrarias (ODEPA), correspondiente al período comprendido entre enero de 2020 y julio de 2026. Además, el conjunto de datos fue enriquecido con variables temporales y meteorológicas para evaluar si estos factores contribuían a mejorar la capacidad predictiva del modelo.

Más que obtener el modelo con la mayor precisión posible, el propósito del proyecto fue desarrollar un flujo completo de Ciencia de Datos, recorriendo todas las etapas habituales de un problema de regresión: obtención de datos, preparación, análisis exploratorio, ingeniería de características, selección de modelos y evaluación del modelo final.

2. Problema abordado

El precio de los productos agrícolas presenta una variación constante producto de múltiples factores, entre ellos la estacionalidad, la ubicación geográfica, las condiciones climáticas y las características propias de cada producto.

A partir de esta información surge la siguiente pregunta:

¿Es posible estimar el precio promedio semanal de una fruta utilizando únicamente información disponible antes del momento de la predicción?

Responder esta pregunta permite evaluar hasta qué punto un modelo de Machine Learning es capaz de capturar los patrones presentes en datos históricos reales.

3. Fuente de los datos

La información principal utilizada en este proyecto proviene del sistema de precios al consumidor publicado por la Oficina de Estudios y Políticas Agrarias (ODEPA).

El conjunto de datos contiene registros semanales desde enero de 2020 hasta julio de 2026 e incluye información como:

- Región.
- Punto de monitoreo.
- Producto y variedad.
- Calidad.
- Semana de observación.
- Precio mínimo.
- Precio máximo.
- Precio promedio.

Como parte del proceso de enriquecimiento del dataset también se incorporaron variables meteorológicas obtenidas con la API Open Meteo con el objetivo de evaluar su posible influencia sobre el comportamiento del precio. Estas fueron:

- Temperatura promedio
 - Temperatura mínima
 - Temperatura máxima
 - Suma de precipitaciones
-

4. Desarrollo del proyecto

El proyecto fue desarrollado siguiendo un flujo de trabajo estructurado, compuesto por las siguientes etapas:

1. Obtención y consolidación de los datos.
2. Limpieza y estandarización del dataset.
3. Análisis exploratorio de datos (EDA).
4. Ingeniería de características.
5. Selección de variables.
6. Comparación de modelos de regresión mediante validación cruzada.
7. Evaluación del modelo seleccionado utilizando un conjunto de prueba independiente.
8. Exportación del pipeline para futuras predicciones.

Durante el desarrollo también se implementaron pipelines de preprocesamiento para asegurar que todas las transformaciones fueran reproducibles y evitar problemas de *data leakage* durante el entrenamiento y la evaluación.

5. Modelos evaluados

Con el objetivo de seleccionar el algoritmo más adecuado, se compararon distintos modelos de regresión utilizando exactamente el mismo procedimiento de validación.

Los modelos evaluados fueron:

- Regresión Lineal
- Árbol de Decisión
- Random Forest Regressor
- Gradient Boosting Regressor
- HistGradientBoosting Regressor

Todos los modelos fueron comparados utilizando validación cruzada y las siguientes métricas:

- Coeficiente de determinación (R^2).
- Error Absoluto Medio (MAE).
- Raíz del Error Cuadrático Medio (RMSE).

Esto permitió realizar una comparación objetiva bajo las mismas condiciones de entrenamiento.

6. Resultados

Los distintos modelos presentaron un comportamiento relativamente similar, aunque los métodos basados en *boosting* obtuvieron el mejor equilibrio entre precisión y tiempo de entrenamiento.

El algoritmo **Hits Gradient Boosting Regressor** fue finalmente seleccionado como modelo candidato debido a su buen desempeño general y su eficiencia computacional.

Los resultados obtenidos muestran que el modelo es capaz de capturar gran parte de la variabilidad presente en los datos. Sin embargo, también evidencian que el precio de los productos agrícolas depende de numerosos factores que no se encuentran disponibles en el conjunto de datos utilizado.

En consecuencia, el modelo debe entenderse como una aproximación basada en la información disponible y no como una representación completa del proceso de formación de precios.

7. Aprendizajes

El principal valor del proyecto no radica únicamente en el modelo obtenido, sino en el proceso seguido para construirlo.

Durante su desarrollo se aplicaron prácticas habituales en proyectos de Ciencia de Datos, entre ellas:

- Obtención e integración de datos provenientes de múltiples fuentes.
- Limpieza y estandarización de datos.
- Análisis exploratorio de datos (EDA).
- Ingeniería y selección de características.
- Construcción de pipelines de preprocesamiento.
- Comparación objetiva de modelos de regresión.
- Validación cruzada para la selección de modelos.
- Evaluación mediante métricas de regresión (R^2 , MAE y RMSE).
- Prevención de *data leakage* durante el entrenamiento y la evaluación.

Más allá del rendimiento alcanzado, el proyecto permitió desarrollar un flujo de trabajo reproducible para abordar un problema de predicción utilizando datos reales.

8. Limitaciones

El desempeño alcanzado por el modelo está condicionado por la información disponible.

Existen numerosos factores que pueden influir sobre el precio de los productos agrícolas y que no fueron considerados dentro del conjunto de datos, como variables económicas, costos de transporte, disponibilidad de oferta, demanda, eventos extraordinarios o factores comerciales.

Algunas de los datos que, conseguir a acceso a ellos; podría permitir re hacer el experimento y evaluar si se consiguen mejores conclusiones serían:

- Época de cultivo y de cosecha para cada fruta
 - Condiciones climáticas para estas nuevas variables temporales
 - Indicadores económicos como IPC y quizá más importante: precio del combustible para inferir el costo agregado por el transporte.
-

9. Hallazgos principales

El desarrollo del proyecto permitió extraer diversas conclusiones tanto sobre el conjunto de datos como sobre el comportamiento de los modelos evaluados.

Hallazgos obtenidos durante el análisis de datos

- El precio promedio presentó una fuerte dependencia con su valor histórico reciente, siendo la variable de rezago (`precio_lag_1`) la característica con mayor capacidad predictiva dentro del conjunto de datos.
- Las variables de precio mínimo y precio máximo mostraron una alta correlación con el precio promedio. Estas fueron excluidas del entrenamiento.
- Las variables categóricas asociadas al producto, particularmente la combinación producto-variedad, demostraron una alta relación con el precio, lo que justificó mantenerlas como variables relevantes dentro del modelo.
- Las variables meteorológicas aportaron información adicional, aunque su influencia fue considerablemente menor que la observada para el historial de precios y las características propias del producto.
- Los valores atípicos identificados durante el análisis correspondían principalmente a observaciones válidas del mercado y no a errores de registro, por lo que fueron conservados dentro del conjunto de datos.
- La distribución de las variables de precio presentó una marcada asimetría positiva (una cola hacia la derecha), lo que motivó la aplicación de transformaciones para reducir el sesgo y facilitar el aprendizaje de los modelos.

Hallazgos obtenidos durante el entrenamiento

- Los modelos basados en árboles obtuvieron un desempeño superior al de la regresión lineal, indicando que la relación entre las variables predictoras y el precio presenta un comportamiento no lineal.
- Entre los algoritmos evaluados, Hist Gradient Boosting Regressor ofreció el mejor equilibrio entre capacidad predictiva y tiempo de entrenamiento, siendo seleccionado como modelo final del proyecto.
- La eliminación de la variable `precio_lag_1` produjo una disminución apreciable en el desempeño del modelo, confirmando que el comportamiento histórico del precio constituye la principal fuente de información para este problema.
- La incorporación de variables meteorológicas acabó aportando muy poca información lo que sugiere la necesidad de replantearse el utilizarlas o el cómo se están utilizando.

Conclusión general

Los resultados obtenidos indican que el precio de una fruta puede estimarse razonablemente utilizando información histórica, temporal y descriptiva del producto. No obstante, el análisis también sugiere que una parte importante de la variabilidad del precio depende de factores externos que no fueron incorporados al conjunto de datos, tales como condiciones económicas, oferta y demanda, costos logísticos o eventos excepcionales.

En consecuencia, el modelo desarrollado representa una aproximación basada en la información disponible y constituye una base sólida para futuras mejoras mediante la incorporación de nuevas fuentes de información.